

---

## Relatório de Análise: Projetos de Investimento no DF (ObrasGov)

**Data:** 17 de Outubro de 2025

### 1. Introdução e Objetivo

Este relatório apresenta os resultados de uma análise exploratória dos dados de projetos de investimento público no Distrito Federal (DF), obtidos através da API da plataforma ObrasGov.br. O objetivo principal foi extrair, tratar e visualizar os dados para identificar padrões de investimento, entender a distribuição de recursos por setor e órgão executor, avaliar o status atual dos projetos e comunicar os insights de forma clara.

### 2. Fonte dos Dados

Os dados foram coletados programaticamente via API pública do ObrasGov.br, utilizando o endpoint /projeto-investimento com filtro para a Unidade Federativa uf=DF. O processo de extração exigiu a implementação de lógicas para lidar com a paginação da API e limites de taxa de requisição (erros 429). Os dados brutos extraídos (834 registros) foram salvos em ../data/raw/.

### 3. Metodologia e Tratamento dos Dados

O processo de análise seguiu um fluxo rigoroso de engenharia e tratamento de dados, documentado no notebook `analise_obrasgov_df.ipynb`:

1. **Aquisição e Carga:** Extração via API e carregamento inicial dos dados brutos.
2. **Limpeza Fundamental:** Criação de uma cópia de trabalho (`df_tratado`) e remoção imediata de registros duplicados baseados no `id_unico` (resultando em 667 registros únicos).
3. **Diagnóstico Pós-Deduplicação:** Análise detalhada da estrutura, tipos de dados, valores ausentes (Nulos) e estatísticas descritivas sobre os dados únicos.
4. **Engenharia de Features (Flattening):** Expansão das colunas com dados estruturados (strings de listas/dicionários como executores, eixos, fontes\_de\_recurso, etc.) em novas colunas "achatadas" (ex: `executor_nome`, `eixo_descricao`, `origem_recurso`).
5. **Cálculo de Métricas:** Criação da coluna `valor_total_previsto` pela soma validada dos valores em `fontes_de_recurso`.
6. **Tipagem Adequada:** Conversão das colunas para os tipos semânticos corretos e otimizados (`datetime64[ns]`, `float64`, `boolean`, `string`, `category`), com validação da escolha baseada na cardinalidade.
7. **Identificação e Registro de Anomalias:** Documentação formal dos problemas de qualidade encontrados (detalhados na seção abaixo).
8. **Otimização e Limpeza Final:** Remoção das colunas originais redundantes do DataFrame master (`df_tratado`).
9. **Armazenamento:** Salvamento do `df_tratado` na tabela `projetos_investimento` do banco SQLite (`../db/obras_df.db`).

10. **Preparação para Análise:** Carregamento dos dados do SQLite, criação do `df_analise` focado na visualização, e filtragem final de 110 registros com valores simbólicos (`valor_total_previsto <= R$ 1`). Salvamento do `df_analise` (557 registros) em `../data/processed/`.

#### 4. Anomalias e Qualidade dos Dados Encontrados

Durante a exploração e tratamento, diversas anomalias e problemas de qualidade foram identificados, impactando a análise e exigindo tratamento específico:

1. **Nomes de Projetos como Identificadores:** Um número significativo de projetos na coluna `nome` continha códigos de processo, contrato ou outros identificadores (ex: 26.782.3006.7XT1.0053, 00 00680/2023, 202111-22-Ronald 1), dificultando a interpretação direta em algumas visualizações. Os dados foram mantidos conforme a origem.
2. **Registros Duplicados e Inconsistentes:** Foram encontrados 158 registros com `id_unico` duplicado. Desses, 99 eram cópias exatas, mas 59 apresentavam dados diferentes em outras colunas, indicando inconsistências na fonte. Adotou-se a estratégia de manter apenas a primeira ocorrência (`keep='first'`).
3. **Valores Simbólicos:** Identificou-se 110 projetos (aprox. 16.5% do total único) com `valor_total_previsto` igual a R\$ 0.00 ou R\$ 0.01. Estes foram considerados *placeholders* ou erros de cadastro e foram **filtrados** do DataFrame `df_analise` para não distorcerem as estatísticas e visualizações de valor.
4. **Alta Porcentagem de Valores Nulos:** Colunas relevantes para análise de impacto, como `qdt_empregos_gerados` (80.51% nulos pós-deduplicação) e `populacao_beneficiada` (80.81% nulos pós-deduplicação), apresentaram preenchimento muito baixo, limitando a profundidade da análise nesses aspectos.

#### 5. Principais Descobertas e Insights

As análises visuais e estatísticas sobre os 557 projetos com valores realistas revelaram os seguintes padrões:

1. **Distribuição de Valores:** A maioria dos projetos se concentra na faixa de **R\$ 1 milhão a R\$ 10 milhões**. A presença de poucos projetos de altíssimo custo (outliers) eleva a média (R\$ 15,07M) muito acima da mediana (R\$ 2,10M).
2. **Evolução Temporal:** Houve um pico expressivo de cadastros (quantidade e valor) em **2021**, seguido por uma estabilização em patamares mais baixos, porém consistentes, nos anos subsequentes (~100 projetos/ano, ~R\$ 1 Bi/ano).
3. **Distribuição Setorial:** O setor **Econômico** domina os investimentos (46.74% do valor), seguido pelo **Social** (25.46%), **Administrativo** (~15%) e **Militar** (~11%).
4. **Principais Executores (por Quantidade):** Órgãos federais lideram, com **DNIT** (70 projetos) à frente, seguido por **IFB** (48) e **FUB (UnB)** (45), destacando o foco em transporte e educação/pesquisa.
5. **Situação dos Projetos:** A grande maioria (**70.38%**) dos projetos está apenas "Cadastrada", indicando um volume significativo de planejamento ainda não iniciado. Apenas ~15% estão "Em execução" e ~10% "Concluídos".

*(Os insights detalhados e as explicações para cada análise encontram-se nas células de Markdown correspondentes dentro do notebook.)*

## **6. Conclusão**

A análise dos dados do ObrasGov para o Distrito Federal oferece um panorama valioso sobre o planejamento e a execução de investimentos públicos. Revelou-se uma concentração de projetos de médio porte, um pico de planejamento em 2021, a dominância do setor econômico e de executores federais, e um grande volume de projetos ainda na fase inicial de cadastro. As anomalias encontradas ressaltam a importância de um tratamento cuidadoso dos dados antes da análise.